

LAPORAN
PROJECT NATURAL LANGUAGE PROCESSING
SPAM DETECTION ON WINDAH BASUDARA YOUTUBE
COMMENTS



SPAM DETECTION

Disusun Oleh:

0110224014	: Aan Adriyana
0110224112	: Muhamad Fadil
0110224030	: Oryza Ayunda Putri
0110224155	: Rafa Al Razzak
0110224081	: Raffa Yuda Pratama

PROGRAM STUDI TEKNIK INFORMATIKA
SEKOLAH TINGGI TEKNOLOGI TERPADU NURUL FIKRI
DEPOK
2026

DAFTAR ISI

DAFTAR ISI.....	1
BAB I	
PENDAHULUAN.....	2
1.1 Latar Belakang.....	2
1.2 Tujuan Project.....	2
BAB II	
LANDASAN TEORI.....	4
2.1 Text Classification.....	4
2.2 Natural Language Processing (NLP).....	4
2.3 Feature Extraction (TF-IDF dan Word Embedding).....	4
2.4 Machine Learning untuk Spam Detection.....	4
2.5 Deep Learning dalam Spam Detection.....	5
BAB III	
HASIL DAN PEMBAHASAN.....	6
3.1 Problem Definition.....	6
3.2 Dataset.....	6
3.3 Exploratory Data Analysis.....	7
3.4 Text Preprocessing.....	7
3.5 Train-Test Split.....	7
3.6 Feature Extraction.....	8
3.7 Modeling.....	8
3.8 Transformer: IndoBERT Fine-Tuned.....	9
3.9 Experiment & Comparison.....	9
3.10 Error Analysis.....	10
3.7 Insight & Analisis.....	10
BAB IV	
KESIMPULAN DAN SARAN.....	11
4.1 Kesimpulan.....	11
4.2 Saran.....	11
DAFTAR PUSTAKA.....	12

BAB I

PENDAHULUAN

1.1 Latar Belakang

YouTube merupakan salah satu platform berbagi video terbesar di dunia yang memungkinkan interaksi dinamis antara kreator dan penonton melalui kolom komentar. Namun, pada kanal dengan basis massa yang sangat besar seperti Windah Basudara, tingginya intensitas interaksi seringkali dibarengi dengan munculnya fenomena spam yang masif. Permasalahan ini muncul dalam berbagai bentuk, mulai dari penggunaan emoji yang berulang secara berlebihan, promosi akun atau layanan yang tidak diinginkan, hingga pesan dengan karakter acak yang tidak memiliki makna kontekstual. Kehadiran spam tersebut tidak hanya mengganggu estetika diskusi, tetapi juga menenggelamkan komentar organik dari penggemar, sehingga kualitas interaksi antara kreator dan komunitas menjadi menurun.

Melakukan moderasi komentar secara manual pada kanal dengan jutaan pengikut adalah pekerjaan yang hampir mustahil dilakukan karena volume data yang masuk sangat cepat. Oleh karena itu, diperlukan solusi teknologi berbasis Natural Language Processing (NLP) yang mampu melakukan klasifikasi otomatis untuk memisahkan komentar yang valid dan sampah. Dalam perkembangannya, terdapat berbagai pendekatan untuk memproses teks, seperti penggunaan metode statistik TF-IDF hingga pendekatan yang lebih modern seperti Word Embedding. Dengan menguji berbagai algoritma Machine Learning, proyek ini diharapkan dapat menemukan solusi yang paling efektif dan akurat dalam menangani karakteristik unik dari bahasa komentar audiens di Indonesia.

1.2 Tujuan Project

Berdasarkan permasalahan di atas, proyek ini disusun dengan tujuan sebagai berikut:

1. Mengembangkan Model Klasifikasi: Membangun sistem yang mampu mengkategorikan komentar secara otomatis ke dalam label Spam (1) atau Non-Spam (0).
2. Eksperimen Representasi Fitur: Melakukan perbandingan performa antara metode TF-IDF (pendekatan berbasis statistik) dan Word Embedding (pendekatan berbasis semantik) untuk menentukan representasi teks yang paling efektif.

3. Evaluasi Algoritma: Membandingkan tiga algoritma Machine Learning yang berbeda untuk menemukan model dengan metrik evaluasi (seperti akurasi, precision, dan recall) terbaik.
4. Implementasi Antarmuka Pengguna: Membangun aplikasi web sederhana menggunakan Gradio sebagai alat demonstrasi model secara real-time, sehingga hasil klasifikasi dapat diuji coba dengan mudah oleh pengguna umum.

BAB II

LANDASAN TEORI

2.1 Text Classification

Text classification adalah proses mengelompokkan teks ke dalam kategori tertentu, seperti spam dan non-spam. Dalam konteks komentar YouTube, klasifikasi ini digunakan untuk memisahkan komentar yang relevan dan tidak relevan secara otomatis. Teknik ini menjadi solusi penting karena mampu menangani data dalam jumlah besar secara efisien [3].

2.2 Natural Language Processing (NLP)

Natural Language Processing adalah bidang yang memungkinkan komputer memahami, memproses, dan menganalisis bahasa manusia. NLP digunakan untuk mengekstrak makna dari teks melalui proses seperti tokenisasi, stemming, dan lemmatization. Dalam analisis komentar YouTube, NLP membantu memahami struktur dan konteks bahasa yang digunakan pengguna [1].

2.3 Feature Extraction (TF-IDF dan Word Embedding)

Salah satu tahap penting dalam NLP adalah representasi teks menjadi bentuk numerik.

1. TF-IDF (Term Frequency-Inverse Document Frequency) digunakan untuk mengukur pentingnya suatu kata dalam dokumen.
2. Word Embedding seperti Word2Vec digunakan untuk menangkap hubungan semantik antar kata.

Pendekatan ini banyak digunakan dalam penelitian spam detection karena mampu meningkatkan akurasi model klasifikasi [2].

2.4 Machine Learning untuk Spam Detection

Machine Learning memungkinkan sistem belajar dari data untuk melakukan klasifikasi otomatis. Beberapa algoritma yang umum digunakan antara lain:

1. Support Vector Machine (SVM)
2. Random Forest
3. XGBoost
4. LinearSVC

Penelitian menunjukkan bahwa model seperti LinearSVC mampu mencapai akurasi tinggi (di atas 95%) dalam mendeteksi spam komentar YouTube [2].

2.5 Deep Learning dalam Spam Detection

Pendekatan modern menggunakan Deep Learning seperti:

1. LSTM (Long Short-Term Memory)
2. CNN (Convolutional Neural Network)
3. GRU

Model LSTM terbukti unggul karena mampu memahami konteks dan urutan kata dalam teks, dengan akurasi mencapai 95.65% dalam deteksi spam komentar YouTube [4].

BAB III

HASIL DAN PEMBAHASAN

3.1 Problem Definition

Permasalahan utama dalam penelitian ini adalah tingginya jumlah komentar spam pada live stream YouTube, khususnya pada kanal Windah Basudara. Komentar spam yang muncul umumnya berupa promosi judi online (judol), tautan tidak relevan, serta pesan berulang yang tidak memiliki makna.

Volume komentar yang besar menyebabkan proses moderasi manual menjadi tidak efektif dan memakan waktu. Oleh karena itu, diperlukan sistem otomatis berbasis Natural Language Processing (NLP) untuk mengklasifikasikan komentar ke dalam dua kategori, yaitu:

- Spam (1)
- Non-spam / Ham (0)

Penelitian ini bertujuan untuk membangun serta membandingkan performa beberapa pendekatan, yaitu:

- Machine Learning klasik berbasis fitur TF-IDF dan Word2Vec
- Deep Learning berbasis Transformer (IndoBERT fine-tuned)

3.2 Dataset

Dataset yang digunakan merupakan kumpulan komentar dari live stream YouTube Windah Basudara yang telah diberi label secara manual.

Karakteristik dataset:

- Data berupa teks komentar
- Label klasifikasi:
 - 1) 0 = Ham (komentar normal)
 - 2) 1 = Spam (komentar judol/promosi)
- Data telah dibersihkan dari missing values
- Digunakan untuk klasifikasi biner

3.3 Exploratory Data Analysis

Tahap eksplorasi data dilakukan untuk memahami karakteristik dataset sebelum proses modeling.

Analisis yang dilakukan meliputi:

- Distribusi jumlah data pada masing-masing kelas
- Distribusi panjang teks komentar
- Analisis kata yang paling sering muncul pada masing-masing kelas

Hasil EDA menunjukkan bahwa:

- Dataset cenderung tidak seimbang (imbalanced)
- Komentar spam memiliki pola kata yang berulang seperti “link”, “daftar”, “cek bio”
- Komentar spam umumnya lebih pendek dan repetitif dibanding komentar normal

3.4 Text Preprocessing

Tahap preprocessing dilakukan khusus untuk model Machine Learning klasik guna membersihkan teks dari noise.

Langkah-langkah preprocessing:

1. Case folding (mengubah semua huruf menjadi lowercase)
2. Menghapus URL (http, www)
3. Menghapus mention (@) dan hashtag (#)
4. Menghapus karakter khusus dan angka
5. Normalisasi whitespace (menghapus spasi berlebih)
6. Tokenisasi
7. Stopword removal (bahasa Indonesia)
8. Menghapus token dengan panjang ≤ 2 karakter

Tujuan preprocessing:

- Mengurangi noise pada data
- Memperjelas informasi penting
- Meningkatkan performa model

Catatan:

Model IndoBERT tidak menggunakan preprocessing manual, karena sudah memiliki tokenizer bawaan yang mampu memahami teks mentah (raw text).

3.5 Train-Test Split

Dataset dibagi menjadi:

- 80% data training
- 20% data testing

Pembagian dilakukan menggunakan stratified split untuk menjaga proporsi kelas tetap seimbang.

Data testing digunakan sebagai hold-out set, sehingga tidak digunakan selama proses training untuk memastikan evaluasi yang objektif.

3.6 Feature Extraction

Pada tahap ini, teks diubah menjadi representasi numerik menggunakan dua metode:

1. TF-IDF

TF-IDF digunakan untuk mengukur pentingnya suatu kata dalam dokumen.

Karakteristik:

- Menggunakan unigram dan bigram
- Maksimal fitur: 10.000
- Output berupa sparse matrix

Metode ini efektif dalam mendeteksi kata-kata khas pada komentar spam.

2. Word2Vec

Word2Vec digunakan untuk menghasilkan representasi kata berbasis makna.

Karakteristik:

- Dimensi vektor: 150
- Representasi dokumen: rata-rata vektor kata
- Output berupa dense vector

Metode ini mampu menangkap hubungan semantik antar kata.

3.7 Modeling

Model yang digunakan dalam penelitian ini terdiri dari beberapa pendekatan:

1. Machine Learning (TF-IDF)

- Complement Naive Bayes
- Logistic Regression
- Linear SVM
- Random Forest
- XGBoost

2. Machine Learning (Word2Vec)

- Logistic Regression
- Light GBM

3. Deep Learning

- IndoBERT (Transformer berbasis Bahasa Indonesia)

Untuk menangani ketidakseimbangan data digunakan:

- Class Weighting
- SMOTE (Synthetic Minority Over-sampling Technique)

3.8 Transformer: IndoBERT Fine-Tuned

Model IndoBERT digunakan sebagai pendekatan Deep Learning yang mampu memahami konteks bahasa secara lebih mendalam.

Karakteristik:

1. Berbasis transformer
2. Fine-tuned untuk mendeteksi judi online (judol)
3. Mampu memahami:
 - Variasi bahasa
 - Leetspeak
 - Pola penulisan tidak baku

Keunggulan:

- Tidak membutuhkan preprocessing manual
- Memahami konteks kalimat secara lebih baik dibanding model klasik

3.9 Experiment & Comparison

Eksperimen dilakukan dengan membandingkan performa model menggunakan metrik:

- Accuracy
- Precision
- Recall
- F1-Score
- ROC-AUC

Hasil eksperimen menunjukkan:

- Model TF-IDF + Linear SVM dan Logistic Regression memberikan performa tinggi dan stabil
- Random Forest dan XGBoost memiliki performa baik namun lebih kompleks
- Word2Vec menghasilkan performa lebih rendah dibanding TF-IDF
- IndoBERT memberikan hasil terbaik dalam memahami konteks bahasa

Secara umum:

- TF-IDF unggul dalam mendeteksi pola kata spam
- IndoBERT unggul dalam memahami konteks kalimat

3.10 Error Analysis

Analisis kesalahan dilakukan untuk memahami kelemahan model:

- False Positive (FP): komentar normal diklasifikasikan sebagai spam
- False Negative (FN): komentar spam tidak terdeteksi

Hasil analisis menunjukkan bahwa:

- Model klasik cenderung salah pada komentar dengan konteks ambigu
- IndoBERT lebih baik dalam mengurangi kesalahan berbasis konteks

3.11 Insight

Beberapa insight yang diperoleh dari penelitian ini:

1. Komentar spam memiliki pola kata yang khas dan berulang
2. TF-IDF sangat efektif untuk klasifikasi spam berbasis keyword
3. Word2Vec kurang optimal pada teks pendek seperti komentar YouTube
4. IndoBERT unggul dalam memahami konteks dan variasi bahasa
5. Preprocessing berpengaruh besar terhadap performa model klasik
6. Ketidakseimbangan data dapat mempengaruhi hasil model sehingga perlu penanganan khusus
7. Kombinasi pendekatan (hybrid) berpotensi memberikan hasil terbaik

BAB IV

KESIMPULAN DAN SARAN

4.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa sistem berbasis Natural Language Processing (NLP) mampu secara efektif mendeteksi komentar spam pada platform YouTube secara otomatis.

Pendekatan Machine Learning klasik menggunakan TF-IDF yang dikombinasikan dengan Logistic Regression dan Linear SVM terbukti memberikan performa yang tinggi, stabil, serta efisien dalam hal komputasi. Model ini sangat cocok digunakan pada lingkungan dengan keterbatasan resource.

Di sisi lain, model Deep Learning berbasis Transformer, yaitu IndoBERT yang telah di-fine-tune, menunjukkan performa terbaik dalam memahami konteks bahasa, termasuk variasi penulisan dan pola kompleks seperti promosi judi online. Hal ini menjadikan IndoBERT sebagai pilihan utama ketika akurasi menjadi prioritas utama.

4.2 Saran

Adapun saran untuk pengembangan penelitian selanjutnya adalah:

1. Menggunakan dataset yang lebih besar dan beragam untuk meningkatkan kemampuan generalisasi model
2. Mengembangkan model Deep Learning lain seperti LSTM atau CNN sebagai pembanding tambahan
3. Melakukan fine-tuning lebih lanjut pada IndoBERT untuk meningkatkan performa
4. Menambahkan fitur berbasis metadata seperti waktu komentar dan perilaku pengguna
5. Mengembangkan sistem hybrid (rule-based + ML + BERT) untuk meningkatkan efisiensi dan akurasi
6. Mengimplementasikan sistem dalam aplikasi nyata untuk moderasi komentar secara real-time
7. Melakukan evaluasi pada data dari platform lain untuk menguji robustness model

DAFTAR PUSTAKA

1. J. Ramos, "Using TF-IDF to Determine Word Relevance in Document Queries," *Proceedings of the First Instructional Conference on Machine Learning*, 2003.
2. T. Mikolov et al., "Efficient Estimation of Word Representations in Vector Space," *arXiv preprint arXiv:1301.3781*, 2013.
3. T. Mikolov et al., "Distributed Representations of Words and Phrases and their Compositionality," *Advances in Neural Information Processing Systems*, 2013.
4. F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
5. C. Cortes and V. Vapnik, "Support-Vector Networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
6. L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
7. T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," *Proceedings of the 22nd ACM SIGKDD*, 2016.
8. G. Ke et al., "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," *Advances in Neural Information Processing Systems*, 2017.
9. J. Devlin et al., "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," *NAACL-HLT*, 2019.
10. B. Wilie et al., "IndoNLU: Benchmark and Resources for Evaluating Indonesian Natural Language Understanding," *Proceedings of AACL-IJCNLP*, 2020.
11. N. V. Chawla et al., "SMOTE: Synthetic Minority Over-sampling Technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
12. I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*, MIT Press, 2016.