

LAPORAN
PROJECT NATURAL LANGUAGE PROCESSING
SPAM DETECTION ON WINDAH BASUDARA YOUTUBE
COMMENTS



SPAM DETECTION

Disusun Oleh:

0110224014	: Aan Adriyana
0110224112	: Muhamad Fadil
0110224030	: Oryza Ayunda Putri
0110224155	: Rafa Al Razzak
0110224081	: Raffa Yuda Pratama

PROGRAM STUDI TEKNIK INFORMATIKA
SEKOLAH TINGGI TEKNOLOGI TERPADU NURUL FIKRI
DEPOK
2026

DAFTAR ISI

DAFTAR ISI.....	1
BAB I	
PENDAHULUAN.....	2
1.1 Latar Belakang.....	2
1.2 Tujuan Project.....	2
BAB II	
LANDASAN TEORI.....	4
2.1 Text Classification.....	4
2.2 Natural Language Processing (NLP).....	4
2.3 Feature Extraction (TF-IDF dan Word Embedding).....	4
2.4 Machine Learning untuk Spam Detection.....	4
2.5 Deep Learning dalam Spam Detection.....	5
BAB III	
HASIL DAN PEMBAHASAN.....	6
3.1 Problem Definition.....	6
3.2 Dataset.....	6
3.3 Exploratory Data Analysis.....	7
3.4 Text Preprocessing.....	7
3.5 Train-Test Split.....	8
3.6 Feature Extraction.....	8
3.7 Modeling.....	9
3.8 Transformer: IndoBERT Fine-Tuned.....	9
3.9 Experiment & Comparison.....	10
3.10 Error Analysis.....	12
3.11 Insight.....	12
3.12 Struktur Repository Github.....	12
3.13 Deployment Aplikasi.....	13
BAB IV	
KESIMPULAN DAN SARAN.....	15
4.1 Kesimpulan.....	15
4.2 Saran.....	15
DAFTAR PUSTAKA.....	17

BAB I

PENDAHULUAN

1.1 Latar Belakang

YouTube merupakan salah satu platform berbagi video terbesar di dunia yang memungkinkan interaksi dinamis antara kreator dan penonton melalui kolom komentar. Namun, pada kanal dengan basis massa yang sangat besar seperti Windah Basudara, tingginya intensitas interaksi seringkali dibarengi dengan munculnya fenomena spam yang masif. Permasalahan ini muncul dalam berbagai bentuk, mulai dari penggunaan emoji yang berulang secara berlebihan, promosi akun atau layanan yang tidak diinginkan, hingga pesan dengan karakter acak yang tidak memiliki makna kontekstual. Kehadiran spam tersebut tidak hanya mengganggu estetika diskusi, tetapi juga menenggelamkan komentar organik dari penggemar, sehingga kualitas interaksi antara kreator dan komunitas menjadi menurun.

Melakukan moderasi komentar secara manual pada kanal dengan jutaan pengikut adalah pekerjaan yang hampir mustahil dilakukan karena volume data yang masuk sangat cepat. Oleh karena itu, diperlukan solusi teknologi berbasis Natural Language Processing (NLP) yang mampu melakukan klasifikasi otomatis untuk memisahkan komentar yang valid dan sampah. Dalam perkembangannya, terdapat berbagai pendekatan untuk memproses teks, seperti penggunaan metode statistik TF-IDF hingga pendekatan yang lebih modern seperti Word Embedding. Dengan menguji berbagai algoritma Machine Learning, proyek ini diharapkan dapat menemukan solusi yang paling efektif dan akurat dalam menangani karakteristik unik dari bahasa komentar audiens di Indonesia.

1.2 Tujuan Project

Berdasarkan permasalahan di atas, proyek ini disusun dengan tujuan sebagai berikut:

1. Mengembangkan Model Klasifikasi

Membangun sistem yang mampu mengkategorikan komentar secara otomatis ke dalam label Spam (1) atau Non-Spam (0).

2. Eksperimen Representasi Fitur

Melakukan perbandingan performa antara metode TF-IDF (pendekatan berbasis

statistik) dan Word Embedding (pendekatan berbasis semantik) untuk menentukan representasi teks yang paling efektif.

3. Evaluasi Algoritma

Membandingkan beberapa algoritma Machine Learning untuk menemukan model dengan performa terbaik berdasarkan metrik evaluasi seperti accuracy, precision, recall, dan F1-score.

4. Implementasi dan Deployment Aplikasi

Mengembangkan aplikasi berbasis web menggunakan Gradio sebagai antarmuka untuk pengujian model secara lokal, serta melakukan deployment aplikasi secara online menggunakan HuggingFace Spaces agar dapat diakses secara publik dan digunakan oleh pengguna secara real-time.

BAB II

LANDASAN TEORI

2.1 Text Classification

Text classification adalah proses mengelompokkan teks ke dalam kategori tertentu, seperti spam dan non-spam. Dalam konteks komentar YouTube, klasifikasi ini digunakan untuk memisahkan komentar yang relevan dan tidak relevan secara otomatis. Teknik ini menjadi solusi penting karena mampu menangani data dalam jumlah besar secara efisien [3].

2.2 Natural Language Processing (NLP)

Natural Language Processing adalah bidang yang memungkinkan komputer memahami, memproses, dan menganalisis bahasa manusia. NLP digunakan untuk mengekstrak makna dari teks melalui proses seperti tokenisasi, stemming, dan lemmatization. Dalam analisis komentar YouTube, NLP membantu memahami struktur dan konteks bahasa yang digunakan pengguna [1].

2.3 Feature Extraction (TF-IDF dan Word Embedding)

Salah satu tahap penting dalam NLP adalah representasi teks menjadi bentuk numerik.

1. TF-IDF (Term Frequency-Inverse Document Frequency) digunakan untuk mengukur pentingnya suatu kata dalam dokumen.
2. Word Embedding seperti Word2Vec digunakan untuk menangkap hubungan semantik antar kata.

Pendekatan ini banyak digunakan dalam penelitian spam detection karena mampu meningkatkan akurasi model klasifikasi [2].

2.4 Machine Learning untuk Spam Detection

Machine Learning memungkinkan sistem belajar dari data untuk melakukan klasifikasi otomatis. Beberapa algoritma yang umum digunakan antara lain:

1. Support Vector Machine (SVM)
2. Random Forest
3. XGBoost
4. LinearSVC

Penelitian menunjukkan bahwa model seperti LinearSVC mampu mencapai akurasi tinggi (di atas 95%) dalam mendeteksi spam komentar YouTube [2].

2.5 Deep Learning dalam Spam Detection

Pendekatan modern menggunakan Deep Learning seperti:

1. LSTM (Long Short-Term Memory)
2. CNN (Convolutional Neural Network)
3. GRU

Model LSTM terbukti unggul karena mampu memahami konteks dan urutan kata dalam teks, dengan akurasi mencapai 95.65% dalam deteksi spam komentar YouTube [4].

BAB III

HASIL DAN PEMBAHASAN

3.1 Problem Definition

Permasalahan utama dalam penelitian ini adalah tingginya jumlah komentar spam pada live stream YouTube, khususnya pada kanal Windah Basudara. Komentar spam yang muncul umumnya berupa promosi judi online (judol), tautan tidak relevan, serta pesan berulang yang tidak memiliki makna.

Volume komentar yang besar menyebabkan proses moderasi manual menjadi tidak efektif dan memakan waktu. Oleh karena itu, diperlukan sistem otomatis berbasis Natural Language Processing (NLP) untuk mengklasifikasikan komentar ke dalam dua kategori, yaitu:

- Spam (1)
- Non-spam / Ham (0)

Penelitian ini bertujuan untuk membangun serta membandingkan performa beberapa pendekatan, yaitu:

- Machine Learning klasik berbasis fitur TF-IDF dan Word2Vec
- Deep Learning berbasis Transformer (IndoBERT fine-tuned)

3.2 Dataset

Dataset yang digunakan merupakan kumpulan komentar dari live stream YouTube Windah Basudara yang telah diberi label secara manual.

Karakteristik dataset:

- Total data: **12.534 komentar** (memenuhi syarat minimal 10.000 data)
- Data berupa teks komentar
- Label klasifikasi:
 - 0 = Ham (komentar normal)
 - 1 = Spam (komentar promosi/judol)

Alasan pemilihan dataset:

- Dataset relevan dengan permasalahan nyata (real-world problem)
- Komentar YouTube memiliki karakteristik unik (bahasa tidak baku, singkatan, emoji)
- Kanal Windah Basudara memiliki volume komentar tinggi sehingga cocok untuk studi kasus spam detection

3.3 Exploratory Data Analysis

Tahap eksplorasi data dilakukan untuk memahami karakteristik dataset sebelum proses modeling.

Analisis yang dilakukan meliputi:

- Distribusi jumlah data pada masing-masing kelas
- Distribusi panjang teks komentar
- Analisis kata yang paling sering muncul pada masing-masing kelas

Distribusi data:

- Total data training: 11.977
- Total data testing: 2.995

Distribusi label pada data training:

- Ham (0): 8.528 (71.2%)
- Spam (1): 3.449 (28.8%)

Distribusi label pada data testing:

- Ham (0): 2.132 (71.2%)
- Spam (1): 863 (28.8%)

Hasil EDA menunjukkan bahwa:

- Dataset tergolong **imbalanced**, dengan dominasi kelas non-spam (sekitar 71%)
- Meskipun tidak ekstrem, ketidakseimbangan ini dapat menyebabkan model cenderung bias terhadap kelas mayoritas (Ham)
- Proporsi spam yang masih cukup signifikan (28.8%) memungkinkan model tetap dapat mempelajari pola spam dengan baik
- Distribusi antara data training dan testing konsisten, sehingga evaluasi model menjadi lebih valid

3.4 Text Preprocessing

Tahap preprocessing dilakukan khusus untuk model Machine Learning klasik guna membersihkan teks dari noise.

Langkah-langkah preprocessing:

1. Case folding (mengubah semua huruf menjadi lowercase)
2. Menghapus URL (http, www)
3. Menghapus mention (@) dan hashtag (#)
4. Menghapus karakter khusus dan angka
5. Normalisasi whitespace (menghapus spasi berlebih)
6. Tokenisasi
7. Stopword removal (bahasa Indonesia)
8. Menghapus token dengan panjang ≤ 2 karakter

Tujuan preprocessing:

- Mengurangi noise pada data
- Memperjelas informasi penting
- Meningkatkan performa model

Catatan:

Model IndoBERT tidak menggunakan preprocessing manual, karena sudah memiliki tokenizer bawaan yang mampu memahami teks mentah (raw text).

3.5 Train-Test Split

Dataset dibagi menjadi:

- 80% data training
- 20% data testing

Pembagian dilakukan menggunakan stratified split untuk menjaga proporsi kelas tetap seimbang.

Data testing digunakan sebagai hold-out set, sehingga tidak digunakan selama proses training untuk memastikan evaluasi yang objektif.

3.6 Feature Extraction

Pada tahap ini, teks diubah menjadi representasi numerik menggunakan dua metode:

1. TF-IDF

TF-IDF digunakan untuk mengukur pentingnya suatu kata dalam dokumen.

Karakteristik:

- Menggunakan unigram dan bigram
- Maksimal fitur: 10.000
- Output berupa sparse matrix

Metode ini efektif dalam mendeteksi kata-kata khas pada komentar spam.

2. Word2Vec

Word2Vec digunakan untuk menghasilkan representasi kata berbasis makna.

Karakteristik:

- Dimensi vektor: 150
- Representasi dokumen: rata-rata vektor kata
- Output berupa dense vector

Metode ini mampu menangkap hubungan semantik antar kata.

3.7 Modeling

Model yang digunakan dalam penelitian ini terdiri dari beberapa pendekatan:

1. Machine Learning (TF-IDF)
 - Complement Naive Bayes
 - Logistic Regression
 - Linear SVM
 - Random Forest
 - XGBoost
2. Machine Learning (Word2Vec)
 - Logistic Regression
 - Light GBM
3. Deep Learning
 - IndoBERT (Transformer berbasis Bahasa Indonesia)

Untuk menangani ketidakseimbangan data digunakan:

- Class Weighting
- SMOTE (Synthetic Minority Over-sampling Technique)

3.8 Transformer: IndoBERT Fine-Tuned

Model IndoBERT digunakan sebagai pendekatan Deep Learning yang mampu memahami konteks bahasa secara lebih mendalam.

Karakteristik:

1. Berbasis transformer
2. Fine-tuned untuk mendeteksi judi online (judol)
3. Mampu memahami:
 - Variasi bahasa
 - Leetspeak
 - Pola penulisan tidak baku

Keunggulan:

- Tidak membutuhkan preprocessing manual
- Memahami konteks kalimat secara lebih baik dibanding model klasik

3.9 Experiment & Comparison

Eksperimen dilakukan dengan membandingkan performa model menggunakan metrik:

- Accuracy
- Precision
- Recall
- F1-Score
- ROC-AUC

Model	Tippe	Accuracy	Precision	Recall	F1-Score	ROC-AUC	Train Time
XGBoost (TF-IDF)	ML Klasik	0.8017	0.7932	0.8017	0.7930	0.8333	16.6s
Logistic Regression (TF-IDF)	ML Klasik	0.7890	0.7975	0.7890	0.7923	0.8420	0.2s
LightGBM (W2V)	ML Klasik	0.7850	0.7947	0.7850	0.7887	0.8357	19.4s
Random Forest (TF-IDF)	ML Klasik	0.7880	0.7852	0.7880	0.7864	0.8244	3.7s
Linear SVM (TF-IDF)	ML Klasik	0.7746	0.7838	0.7746	0.7782	0.8226	0.1s
Complement NB (TF-IDF)	ML Klasik	0.7726	0.7783	0.7726	0.7751	0.8236	0.0s
Logistic Regression (W2V)	ML Klasik	0.7396	0.7698	0.7396	0.7485	0.8031	1.4s
IndoBERT Fine-Tuned	Transformer	0.6935	0.5978	0.6935	0.6069	0.5129	505.7s

Berdasarkan hasil eksperimen yang telah dilakukan, diperoleh beberapa temuan penting:

1. Model terbaik secara keseluruhan

- XGBoost dengan TF-IDF menunjukkan performa terbaik dengan:
 - Accuracy: 0.8017
 - F1-Score: 0.7930
- Hal ini menunjukkan bahwa model ensemble berbasis boosting sangat efektif dalam menangkap pola spam.

2. Model paling efisien

- Logistic Regression dan Linear SVM memiliki waktu training sangat cepat (<1 detik)
- Cocok untuk implementasi real-time

3. Perbandingan TF-IDF vs Word2Vec

- Model berbasis TF-IDF secara konsisten lebih unggul dibanding Word2Vec
- Hal ini disebabkan karena:
 - Data berupa teks pendek
 - Spam memiliki pola keyword yang kuat

4. Performa IndoBERT

- IndoBERT memiliki performa paling rendah pada eksperimen ini
- Kemungkinan penyebab:
 - Dataset relatif kecil untuk deep learning
 - Waktu training terbatas
 - Belum optimal fine-tuning

5. ROC-AUC tertinggi

- Logistic Regression (TF-IDF): 0.8420
- Menunjukkan kemampuan pemisahan kelas yang sangat baik

Performa IndoBERT yang lebih rendah kemungkinan disebabkan oleh keterbatasan jumlah data serta proses fine-tuning yang belum optimal. Model transformer umumnya membutuhkan dataset yang lebih besar agar dapat bekerja secara maksimal.

3.10 Error Analysis

Analisis kesalahan dilakukan untuk memahami kelemahan model:

- False Positive (FP): komentar normal diklasifikasikan sebagai spam
- False Negative (FN): komentar spam tidak terdeteksi

Hasil analisis menunjukkan bahwa:

- Model klasik cenderung salah pada komentar dengan konteks ambigu
- IndoBERT lebih baik dalam mengurangi kesalahan berbasis konteks

3.11 Insight


Beberapa insight yang diperoleh dari penelitian ini:

1. Komentar spam memiliki pola kata yang khas dan berulang
2. TF-IDF sangat efektif untuk klasifikasi spam berbasis keyword
3. Word2Vec kurang optimal pada teks pendek seperti komentar YouTube
4. IndoBERT unggul dalam memahami konteks dan variasi bahasa
5. Preprocessing berpengaruh besar terhadap performa model klasik
6. Ketidakseimbangan data dapat mempengaruhi hasil model sehingga perlu penanganan khusus
7. Kombinasi pendekatan (hybrid) berpotensi memberikan hasil terbaik

3.12 Struktur Repository Github

Struktur repository project adalah sebagai berikut:

brody-spam-detection-main/



Link GitHub: <https://github.com/sttnf/brody-spam-detection>

3.13 Deployment Aplikasi

Aplikasi dikembangkan menggunakan Gradio sebagai antarmuka utama untuk melakukan pengujian model secara interaktif.

Tahapan deployment dilakukan dalam dua bentuk:

1. **Local Development (Gradio)**
 - Digunakan untuk testing dan eksperimen selama proses pengembangan
 - Memungkinkan pengujian cepat terhadap berbagai model
2. **Online Deployment (HuggingFace Spaces)**
 - Aplikasi dideploy secara online menggunakan HuggingFace Spaces
 - Memungkinkan model diakses secara publik tanpa perlu instalasi lokal
 - Mendukung integrasi langsung dengan Gradio


Fitur aplikasi:

- Input teks komentar
- Output klasifikasi (Spam / Non-Spam)
- Probabilitas prediksi

Keunggulan deployment menggunakan HuggingFace Spaces:

- Mudah diakses melalui browser
- Tidak memerlukan setup environment oleh user
- Mendukung demo interaktif secara real-time

Screenshot Aplikasi Spam Detection



Windah Basudara — Spam Shield

Sistem deteksi spam & judi online otomatis.

Single Detection Batch Processing

Input Komentar

test

Pilih Viewport

Ensemble (All Models)

Deteksi Sekarang

✓ **HASIL: KOMENTAR AMAN**

(6/8 model setuju)

Model	Fitur	Prediksi	Score
Logistic Regression	TF-IDF	✓ HAM	36.04%
Complement NB	TF-IDF	✓ HAM	50.00%
Linear SVM	TF-IDF	✓ HAM	0.00%
Random Forest	TF-IDF	✓ HAM	46.16%
XGBoost	TF-IDF	✓ HAM	19.20%
Logistic Regression (W2V)	Word2Vec	✗ SPAM	56.85%
LightGBM (W2V)	Word2Vec	✗ SPAM	62.28%
IndoBERT Fine-Tuned	Transformer	✓ HAM	0.01%

Link Deployment

Aplikasi dapat diakses secara online melalui HuggingFace Spaces pada link berikut:

<https://huggingface.co/spaces/rafaalrazzak/spam-detection>

BAB IV

KESIMPULAN DAN SARAN

4.1 Kesimpulan

Hasil eksperimen menunjukkan bahwa pendekatan *Machine Learning* klasik berbasis TF-IDF memberikan performa terbaik dibandingkan metode lainnya. Model XGBoost dengan representasi TF-IDF menjadi model dengan kinerja paling optimal, ditunjukkan oleh nilai accuracy sebesar 0.8017 dan F1-score sebesar 0.7930. Hal ini menunjukkan bahwa metode berbasis frekuensi kata sangat efektif dalam mendeteksi pola spam yang cenderung memiliki karakteristik kata yang khas dan berulang.

Selain itu, model seperti Logistic Regression dan Linear SVM juga menunjukkan performa yang stabil dengan waktu komputasi yang sangat cepat, sehingga cocok untuk implementasi pada sistem real-time dengan keterbatasan sumber daya.

Sebaliknya, pendekatan berbasis Word2Vec menghasilkan performa yang lebih rendah dibandingkan TF-IDF. Hal ini disebabkan oleh karakteristik data yang berupa teks pendek, sehingga representasi berbasis semantik kurang mampu menangkap pola spam secara optimal.

Sementara itu, model *Deep Learning* berbasis Transformer, yaitu IndoBERT yang telah di-*fine-tune*, belum menunjukkan performa yang optimal pada penelitian ini. Hal ini kemungkinan disebabkan oleh keterbatasan jumlah data serta proses *fine-tuning* yang belum maksimal. Model transformer umumnya memerlukan dataset yang lebih besar agar dapat memahami konteks bahasa secara lebih efektif.

Dengan demikian, dapat disimpulkan bahwa untuk kasus deteksi spam pada komentar YouTube dengan karakteristik teks pendek, pendekatan *Machine Learning* klasik berbasis TF-IDF masih menjadi pilihan yang paling efektif dan efisien.

4.2 Saran

Adapun saran untuk pengembangan penelitian selanjutnya adalah:

1. Menggunakan dataset yang lebih besar dan beragam untuk meningkatkan kemampuan generalisasi model

2. Mengembangkan model Deep Learning lain seperti LSTM atau CNN sebagai pembandingan tambahan
3. Melakukan fine-tuning lebih lanjut pada IndoBERT untuk meningkatkan performa
4. Menambahkan fitur berbasis metadata seperti waktu komentar dan perilaku pengguna
5. Mengembangkan sistem hybrid (rule-based + ML + BERT) untuk meningkatkan efisiensi dan akurasi
6. Mengimplementasikan sistem dalam aplikasi nyata untuk moderasi komentar secara real-time
7. Melakukan evaluasi pada data dari platform lain untuk menguji robustness model

DAFTAR PUSTAKA

1. J. Ramos, "Using TF-IDF to Determine Word Relevance in Document Queries," *Proceedings of the First Instructional Conference on Machine Learning*, 2003.
2. T. Mikolov et al., "Efficient Estimation of Word Representations in Vector Space," *arXiv preprint arXiv:1301.3781*, 2013.
3. T. Mikolov et al., "Distributed Representations of Words and Phrases and their Compositionality," *Advances in Neural Information Processing Systems*, 2013.
4. F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
5. C. Cortes and V. Vapnik, "Support-Vector Networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
6. L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
7. T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," *Proceedings of the 22nd ACM SIGKDD*, 2016.
8. G. Ke et al., "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," *Advances in Neural Information Processing Systems*, 2017.
9. J. Devlin et al., "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," *NAACL-HLT*, 2019.
10. B. Wilie et al., "IndoNLU: Benchmark and Resources for Evaluating Indonesian Natural Language Understanding," *Proceedings of AACL-IJCNLP*, 2020.
11. N. V. Chawla et al., "SMOTE: Synthetic Minority Over-sampling Technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
12. I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*, MIT Press, 2016.